


상품 뒷면 이미지 소비기한 추출: 파이프라인 아키텍처

CPU 단독 40분 제한을 기준으로, 비용이 저렴한 칸에서 대부분을 처리하고 실패한 이미지에만 비용이 더 큰 칸을 계산 제3회 ITDA 연합학술제 본선 식으로 적용했다. [DScover]_카피바라 2026-10-03

직접 라벨링한 828장으로 설계·검증했으며, 최종 성능은 한 번도 설계에 사용하지 않은 248장에서 측정했다.



단계	하는 일	이렇게 한 근거 (실측)
RapidOCR	PP-OCRv6 det + rec 를 ONNX 로 한 번에. 30MB	엔진 세대가 성능을 갈랐다. 같은 평가셋에서 v3+v4 조합 66.8%, v6 조합 79.8%
재지도 계단	실패한 이미지에만 det medium → CLAHE 를 차례로 적용	det medium 을 처음부터 사용하면 맞히던 2장이 망가진다. 실패분에만 길면 그 회귀가 사라져 최종 판정에서 악화 0장
온전한 날짜만 성공 처리	반쪽짜리는 모아 두었다가 모든 칸이 실패했을 때만 사용	부분 결과가 계단을 멈춰 세워, 다음 칸이 2021.11.19 를 읽을 수 있는데도 NONE-11-19 에 머물렀다. 이 한 줄이 가장 큰 기여
2자리 연도	24/11/21 처럼 모호하면 한국식 YY.MM.DD 로 해석	두 집합에서 독립 확인. 유럽식 52.2% / 55.6%, 한국식 91.3% / 92.6%
박스 필터	rec 없이 계산되는 영상 특징으로 상위 K개만 통과	rec 가 보조 경로 비용의 80.9%를 차지하는데, det 가 제안한 전체 박스 26,499개 중 날짜가 파싱되는 것은 0.63%(167개)뿐이다

92.1% 필드 정확도 (미사용 248장)	0.95초 장당 처리시간 (단일 프로세스 순차)	20% 500장 약 474초 제한 2,400초 대비	828장 직접 라벨링 (배분분의 24.7%)
-------------------------------	----------------------------------	------------------------------------	--------------------------------

필드 정확도: 연·월·일을 각각 독립 채점해 맞힌 필드 수 ÷ 전체 필드 수(248장 × 3필드 = 744). 운영진 채점 방식(부분점수)과 동일하며 95% 신뢰구간은 89.9~93.8%. 장당 처리시간: 제출 노트북과 같은 단일 프로세스 순차 루프로 측정했다.

본선 라운드에서 무엇이 얼마나 기여했는가 개선 근거

기여도는 라벨 580장에서 하나씩 붙여 가며 측정했다(기준선 = 예선 구성 92.4%). 이 표본은 오답을 직접 들여다봤으므로 낙관 편향이 있다. 절대 수치는 미사용 248장을 쓴다.

불린 것	필드 정확도 (580장)	기여	왜 이것을 붙였는가
부분 결과가 계단을 막던 버그	92.9%	+0.5%p	OCR 이 정확히 읽은 날짜를 반쪽짜리 결과가 가로막고 있었다
규칙 보강 3종	93.9%	+1.0%p	01 SEP 2023 · JUL 22 21 형식 추가, 202512.20 구분자 결손 처리, 2026.08 + 22:14 에서 시각이 일(日)로 먹히던 것 차단
CLAHE 재지도 칸	94.1%	+0.2%p	전처리 11종 중 유일하게 남은 것. 회수는 23장 중 3장뿐이었다
인식기를 바꾼 칸 (한국어 → 영문)	—	+1.1%p	주력 인식기가 중국어 모델이라 한글을 못 읽는다. 한글이 날짜에 붙어 있으면 (유통2023.01.05 까지) 날짜까지 깨진다. 이 수치는 미사용 표본에서 잦 것

미사용 248장 최종: 92.1% (95% 신뢰구간 89.9~93.8%). 예선 구성과의 비교는 88.5% → 91.9%(+3.4%p, 개선 7장 / 악화 0장, p=0.0156)이고 인식기 칸이 +1.1%p 를 더했다. 악화 0장은 구조 때문이다 — 재지도 칸은 실패한 이미지에만 진입한다.


실측으로 기각한 선택지: 채택한 것보다 기각한 것이 많다 논리성 증거

시도	측정 결과	시도	측정 결과
입력 해상도 상향 (960→3200px)	recall 불변, 비용 1.7배	위원회 기반 액티브 러닝	무작위 표집 대비 이득 없음
단일 전처리 13종 상시 적용	+3.0%p, p=0.201	EasyOCR 파이프라인 결합	+0.0%p (상호보완 0장)
크롭 TTA (박스 변형 재인식)	68.4% → 62.5%	EAN-13 바코드로 연도 순서 판별	발동 가능 이미지 0장
느슨한 꼬리 패턴 추가	64.5% → 63.8%	det server 재지도 칸 (109MB)	다른 집합 17장 → 평가셋 0장
흐릿한 사진 전용 전처리	오답이 오히려 또렷했다 (458 대 412)	1600px 재지도 칸	580장 +0.6%p → 미사용 표본 0장
		다수결 (세 파이프라인 / 여덟 칸)	79.8%→69.2% · 93.6%→93.4%

모든 채택 판정을 설계에 사용하지 않은 평가셋으로만 내렸다. 그 덕분에 1600px 칸처럼 오염된 표본에서만 좋아 보이던 변경을 걸러낼 수 있었다.

1. 어떤 숫자가 소비기한인가: 판별 규칙

설계 의도



이것이 과제의 본질이다. 상품 뒷면에는 제조일자·바코드·품목보고번호·전화번호·영양성분이 함께 인쇄돼 있어, 날짜 형태의 숫자를 찾는 것만으로는 부족하다. 그중 무엇이 소비기한인지를 가려야 한다.

OCR 은 2022와 02.14 를 다른 줄로 끊는데, 인접 조각을 이어 붙이면 복구된다. 비용 0에 48% → 68%로 단일 최대 개선이었다.

규칙	실측 근거
4자리 연도 우선	정밀도 99.2% (2자리는 79.4%)
제조/소비 쌍이면 낮은 날짜	해당 사례 전부에서 성립
9자리+ 숫자 내부 매치 차단	품목보고번호 20130628332176 오탐
미래성 필터 금지	정답에 2020~2022년 과거 날짜 다수
부분 필드 출력	연·월·일이 독립 채점이므로 버리지 않고 회수

2. 제한된 CPU 환경에서의 속도·오탐 최적화

최적화 전략

전략	근거가 된 실측
비용이 저렴한 경로로 90% 처리 2계층 구조	주력 0.37초 / 보조 2.19초. 보조가 필요한 이미지는 전체의 5%
인식 호출을 줄인다 박스 사전 필터(보조)	rec 가 보조 경로 비용의 80.9%. det 박스 26,499개 중 날짜는 0.63%
해상도를 낮춘다 960 → 640px (보조)	위로만 시험한 것이 실수였다. 내리자 정확도 +8.8%p, 비용 62%
실패한 것만 재시도 적응형 재시도	상시 전처리는 유의성 없음(p=0.201). 성공한 이미지를 오히려 손상시킨다
torch 를 포함하지 않는다 전 경로 ONNX	임포트만 해도 2.76 → 5.88초/장. paddle 과 OpenMP 스레드를 결합한다

측정 기준	장당	500장 환산	제한 대비
① 추론 루프만 (모델 로딩 제외, 60장)			
torch 포함 환경 (참고)	5.88초	2,939초	122% ×
보조 경로 단독	2.19초	1,096초	46%
주력 경로 단독	0.37초	184초	8%
1차 예선 제출 구성	0.53초	267초	11%
② 본선 구성 · 단일 프로세스 순차 (120장)			
계단 4칸 + 보조	0.81초	404초	17%

계단이 늘어 예선 구성보다 1.5배 느려졌지만 제한의 17%로 여유가 있다. 82%가 1칸에서 끝나고(중앙값 0.40초) 계단을 끝까지 오르는 9%가 시간을 사용한다.

가장 큰 속도 저하는 torch 가 포함된 환경에서 발생했다.

set_num_threads(1) · KMP_BLOCKTIME=0 · OMP_WAIT_POLICY=PASSIVE 를 모두 시도했지만 6초대에서 내려오지 않아 500장이 제한을 초과했다. 가중치를 ONNX 로 내보내 torch 를 제거하는 것이 해법이었고(변환 전후 박스 IoU 1.000 확인), 후보였던 EasyOCR 파이프라인도 같은 이유로 탈락했다. 그 결과 정확도를 높이면서 속도도 함께 개선됐다.

3. 데이터 직접 라벨링

가산점 증빙

배포 데이터 3,352장은 정답 라벨이 전혀 없다. 자체 도구(label/index.html)를 만들어 직접 판독·검수한 728장(배포분의 21.7%)으로 설계하고 검증했다. 이 라벨이 없었다면 세 파이프라인 중 어느 것이 나은지 판단할 방법 자체가 없었다. 실제로 최종 채택된 구성은 자체 평가("값이 채워진 행 수")만으로는 열세로 보이던 쪽이었다.

평가셋을 세 번 새로 만들었다. 오답을 한 장씩 들여다보며 고치면 그 표본은 더 이상 성능의 근거가 되지 못한다. 그래서 오답 검토에 사용한 표본은 버리고 남은 이미지에서 새로 뽑아 라벨링하기를 반복했다. 편향의 크기도 직접 측정했다. 오답을 들여다본 580장에서는 94.1%, 한 번도 사용하지 않은 148장에서는 91.9%로, 그 차이 2.2%p 가 낙관 편향이다. 보고하는 수치는 91.9%(95% 신뢰 구간 89.0~94.1%)이다.

집합	장수	용도 · 상태
튜닝셋	137	규칙 설계·파라미터 결정
1차 홀드아웃	48	연도 후행형 버그 발견
2차 홀드아웃	198	예선 판정 · 이후 오답 검토로 소진
3차 홀드아웃	197	중간 판정 · 오답 검토로 소진
4차 홀드아웃	148	본선 최종 판정 (미사용 표본)

라벨링 기준은 문서로 먼저 고정했다. 소비기한과 제조일자가 함께 인쇄되면 낮은 쪽, 일부 필드만 읽히면 그 필드만, 판독 불가·중의적인 7장은 제외. 무작위 30장을 사람이 다시 읽어 대조했을 때 30/30 일치했다(0건 오류의 95% 신뢰상한은 약 10%).

4. 추후 활용 계획 및 확장성

활용 전략

적용 도메인	운영 구조	이 아키텍처가 맞는 이유
편의점·마트 유통기한 관리 진열대 촬영 → 임박 상품 자동 집계	온디바이스(모바일 CPU), 주력 엔진만 사용하면 30MB·0.37초/장. 추론 단계에서 서버 왕복이 없어 네트워크 의존성과 통신 비용을 줄일 수 있음	GPU 를 전제하지 않아 그대로 단말에 올라간다. 성능이 낮은 단말은 보조 경로를 꺼서 축소 운용
푸드뱅크 기부 식품 선별 기부 물품의 잔여 기한 일괄 판정	배치 서버. 단일 프로세스 시간당 약 6,800장, 코어 수만큼 병렬 확장	필드별 부분 출력(NONE-08-25)이 사람 검수 대상을 좁혀 준다
물류창고 입고고 자동화 입고 시 기한 판독 → 선입선출	옛지 게이트웨이 + 컨베이어 카메라	확장 경로는 엔진 교체다. OCR 엔진과 날짜 판별 규칙을 분리해, 엔진 교체 시 후처리 로직을 재사용할 수 있도록 설계했다