

상품 뒷면 이미지 소비기한 추출: 파이프라인 아키텍처


CPU 단독·40분 제한을 기준으로, 비용이 저렴한 주력 경로에서 대부분을 처리하고 실패한 이미지에만 비용이 더 큰 보조 경로를 적용했다.

제3회 ITDA 연합학술제 1차 예선

직접 라벨링한 383장으로 설계·검증했으며, 최종 성능은 198장 평가셋에서 측정했다.

[DScover]_카피바라

2026-09-15



단계	하는 일	이렇게 한 근거 (실측)
RapidOCR	PP-OCRv6 det + rec 를 ONNX 로 한 번에. 30MB	엔진 세대가 성능을 갈랐다. 같은 평가셋에서 v3+v4 조합 66.8%, v6 조합 79.8%
날짜 판별	인접 조각 이어붙이기 → 키워드 가중 → 달력 검증	OCR 은 2022 와 02.14 를 다른 줄로 끊는다. 이어 붙이기가 비용 0에 48% → 68%
YOLOv8n	날짜 영역만 배운 전용 검출기 (직접 학습, 11MB)	범용 det 는 20.06.24 를 20 / 06 / 24 로 조각낸다. 보조 경로 +2.4%p
박스 필터	rec 없이 계산되는 영상 특징으로 상위 K개만 통과	rec 가 보조 경로 비용의 80.9%를 차지하는데, det 가 제안한 전체 텍스트 박스 26,499개 중 날짜가 파싱되는 것은 0.63%(167개)뿐이다

82.3%

필드 정확도
(198장 평가셋)

0.92초

장당 처리시간
(채점 명령 실효)

19%

500장 약 460초
제한 2,400초 대비


66MB

모델 총 용량
(v6 + v3/v4 + YOLO)

필드 정확도: 연·월·일을 각각 독립 채점에 맞힌 필드 수 ÷ 전체 필드 수(198장 × 3필드 = 594). 운영진 채점 방식(부분점수)과 동일하다. **장당 처리시간:** 실제 채점 명령 (jupyter nbconvert --execute)으로 188장을 돌린 값이며 모델 로딩 시간을 포함한다.

두 경로를 선택한 근거: 동일 평가셋에서 세 파이프라인 비교

선택 근거



가장 큰 교훈은 엔진 세대였다. v3+v4 조합과 v6 조합의 차이가 +13.0%p (개선 49장 / 악화 14장, McNemar $p < 0.0001$). 후처리 규칙과 전처리 개선보다 OCR 엔진 세대 변경이 더 큰 성능 향상을 보였다. 최적화를 시작하기 전에 엔진 세대를 먼저 확인했어야 했다는 점이 이번 과정의 교훈이다.

실측으로 기각한 선택지: 채택한 것보다 기각한 것이 많다

논리적 증거

시도	측정 결과	시도	측정 결과
입력 해상도 상향 (960→3200px)	recall 불변, 비용 1.7배	위원회 기반 액티브 러닝	무작위 표집 대비 이득 없음
단일 전처리 13종 상시 적용	+3.0%p, $p=0.201$	EasyOCR 파이프라인 결합	+0.0%p (상호보완 0장)
크롭 TTA (박스 변형 재인식)	68.4% → 62.5%	EAN-13 바코드로 연도 순서 판별	발동 가능 이미지 0장
느슨한 꼬리 패턴 추가	64.5% → 63.8%	세 파이프라인 다수결	79.8% → 69.2%


합성·회귀 테스트를 통과하고도 평가셋에서 성능이 낮아져 탈락한 변경이 두 건 있었다. 이후 모든 채택 판정을 설계에 사용하지 않은 평가셋의 필드 정확도로만 내렸다.

채택한 것보다 기각한 것이 더 많다. 아래 수치는 전부 직접 측정했고, 틀렸던 판단도 그대로 남겼다.

2026-09-15

1. 어떤 숫자가 소비기한인가: 판별 규칙

설계 의도



이것이 과제의 본질이다. 상품 뒷면에는 제조일자·바코드·품목보고번호·전화번호·영양성분이 함께 인쇄돼 있어, 날짜 형태의 숫자를 찾는 것만으로는 부족하다. **그중 무엇이 소비기한인지를 가려야 한다.**

OCR 은 2022 와 02.14 를 다른 줄로 끊는데, 인접 조각을 이어 붙이면 복귀된다. **비용 0에 48% → 68%**로 단일 최대 개선이었다.

규칙	실측 근거
4자리 연도 우선	정밀도 99.2% (2자리는 79.4%)
제조/소비 쌍이면 낮은 날짜	해당 사례 전부에서 성립
9자리+ 숫자 내부 매치 차단	품목보고번호 20130628332176 오탐
미래성 필터 금지	정답에 2020~2022년 과거 날짜 다수
부분 필드 출력	연·월·일이 독립 채점이므로 버리지 않고 회수

2. 제한된 CPU 환경에서의 속도·오탐 최적화

최적화 전략

전략	근거가 된 실측
비용이 저렴한 경로로 90% 처리 2계층 구조	주력 0.37초 / 보조 2.19초. 보조가 필요한 이미지는 전체의 5%
인식 호출을 줄인다 박스 사전 필터(보조)	rec 가 보조 경로 비용의 80.9%. det 박스 26,499개 중 날짜는 0.63%
해상도를 낮춘다 960 → 640px (보조)	위로만 시험한 것이 실수였다. 내리자 정확도 +8.8%p, 비용 62%
실패한 것만 재시도 적응형 재시도	상시 전처리하는 유익성 없음(p=0.201). 성공한 이미지를 오히려 손상시킨다
torch 를 포함하지 않는다 전 경로 ONNX	임포트만 해도 2.76 → 5.88초/장. paddle 과 OpenMP 스레드를 결합한다

측정 기준	장당	500장 환산	제한 대비
① 추론 루프만 (모델 로딩 제외, 60장)			
torch 포함 환경 (참고)	5.88초	2,939초	122% ×
보조 경로 단독	2.19초	1,096초	46%
주력 경로 단독	0.37초	184초	8%
최종 구성	0.53초	267초	11%
② 실제 채점 명령 (모델 로딩 포함, 188장)			
최종 구성	0.87~0.92초	약 460초	19%

②가 채점에서 실제로 측정되는 값이다. ①과의 차이는 모델 로딩(약 2초)과 평가 표본의 난이도에서 온다. 1페이지에는 보수적으로 ②를 표기했다.

가장 큰 속도 저하는 torch 가 포함된 환경에서 발생했다.

set_num_threads(1) · KMP_BLOCKTIME=0 · OMP_WAIT_POLICY=PASSIVE 를 모두 시도했지만 6초대에서 내려오지 않아 500장이 제한을 초과했다. 가중치를 ONNX 로 내보내 torch 를 제거하는 것이 해법이었고(변환 전후 박스 IoU 1.000 확인), 후보였던 EasyOCR 파이프라인도 같은 이유로 탈락했다. 그 결과 **정확도를 높이면서 속도도 함께 개선됐다.**

3. 데이터 직접 라벨링

가산점 증빙

배포 데이터 3,352장은 **정답 라벨이 전혀 없다**. 자체 도구(label/index.html)를 만들어 직접 판독·검수한 383장으로 설계하고 검증했다. **이 라벨이 없었다면 세 파이프라인 중 어느 것이 나온지 판단할 방법 자체가 없었다**. 실제로 최종 채택된 구성은 자체 평가("값이 채워진 행 수")만으로는 열세로 보이던 쪽이었다.

검증상의 한계. 198장 평가셋은 보조 경로의 일부 설정 검토에 사용되어 완전히 독립적인 홀드아웃은 아니다. 따라서 이 평가셋에서 측정한 성능에는 다소 낙관적인 편향이 포함될 가능성이 있다. 반면 최종 채택한 주력 경로는 해당 평가셋을 기준으로 직접 튜닝하지 않았으며, 이 점을 감안해 결과를 해석할 필요가 있다. 표본 198장의 95% 신뢰구간은 ±7%p 수준이다.

집합	장수	용도
튜닝셋	137	규칙 설계·파라미터 결정
1차 홀드아웃	48	연도 후행형 버그 발견
2차 홀드아웃	198	최종 성능 판정

라벨링 기준은 문서로 먼저 고정했다. 소비기한과 제조일자가 함께 인쇄되면 **낮은 쪽**, 판독 불가·중의적인 2장은 **제외**.

4. 추후 활용 계획 및 확장성

활용 전략

적용 도메인	운영 구조	이 아키텍처가 맞는 이유
편의점·마트 유통기한 관리 진열대 촬영 → 임박 상품 자동 집계	온디바이스(모바일 CPU). 주력 엔진만 사용하면 30MB·0.37초/장. 추론 단계에서 서버 왕복이 없어 네트워크 의존성과 통신 비용을 줄일 수 있음	GPU 를 전제하지 않아 그대로 단말에 올라간다 . 성능이 낮은 단말은 보조 경로를 꺼서 축소 운용
푸드뱅크 기부 식품 선별 기부 물품의 잔여 기한 일괄 판정	배치 서버. 단일 프로세스 시간당 약 6,800장, 코어 수만큼 병렬 확장	필드별 부분 출력(NONE-08-25)이 사람 검수 대상을 좁혀 준다
물류창고 입고고 자동화 입고 시 기한 판독 → 선입선출	엣지 게이트웨이 + 컨베이어 카메라	확장 경로는 엔진 교체다. OCR 엔진과 날짜 판별 규칙을 분리해, 엔진 교체 시 후처리 로직을 재사용할 수 있도록 설계했다