


상품 뒷면 이미지 소비기한 추출 — 파이프라인 아키텍처

CPU 단독·40분 제한에서 역산한 설계. **싼 경로로 대부분을 끝내고, 실패한 것에만 비싼 경로를 쓴다**가 축이다.
모든 수치는 직접 라벨링한 383장 실측이며, 설계에 한 번도 쓰지 않은 홀드아웃 198장으로 검증했다.

제3회 ITDA 연합학술제 1차 예선
[DScover] 카피바라
2026-09-14



단계	하는 일	이렇게 한 근거 (실측)
RapidOCR	PP-OCrv6 det + rec 를 ONNX 로 한 번에. 30MB	엔진 세대가 성능을 갈랐다 — 같은 홀드아웃에서 v3+v4 조합 66.8%, v6 조합 79.8%
날짜 판별	인접 조각 이어붙이기 → 키워드 가중 → 달력 검증	OCR 은 2022 와 02.14 를 다른 줄로 끊는다. 이어 붙이기가 비용 0에 48% → 68%
YOLOv8n	날짜 영역만 배운 전용 검출기 (직접 학습, 11MB)	범용 det 는 20.06.24 를 20 / 06 / 24 로 조각낸다. 보조 경로 +2.4%p
박스 필터	rec 없이 계산되는 영상 특징으로 상위 K개만 통과	rec 가 보조 경로 비용의 80.9%인데 날짜가 든 박스는 0.63%

82.3%
부분점수
(홀드아웃 198장)


0.53초
장당 추론
(CPU 단일 프로세스)

11%
500장 267초
제한 2,400초 대비

66MB
모델 총 용량
(v6 + v3/v4 + YOLO)

왜 두 경로인가 — 세 파이프라인을 같은 자로 재고 골랐다

선택 근거



가장 큰 교훈은 엔진 세대였다. v3+v4 조합과 v6 조합의 차이가 +13.0%p (개선 49장 / 악화 14장, McNemar p=0.0000). 규칙·해상도 사다리·전용 검출기로 메우려던 격차를 최신 검출기가 그냥 넘었다 — 최적화를 시작하기 전에 엔진 세대를 먼저 확인했어야 했다.

실측으로 기각한 선택지 — 채택한 것보다 기각한 것이 많다


논리성 증거

시도	측정 결과	시도	측정 결과
입력 해상도 상향 (960 → 3200px)	recall 불변, 비용 1.7배	위원회 기반 액티브 러닝	무작위 표집 대비 이득 없음
단일 전처리 13종 상시 적용	+3.0%p, p=0.201	EasyOCR 파이프라인 결합	+0.0%p (상호보완 0장)
크롭 TTA (박스 변형 재인식)	68.4% → 62.5%	EAN-13 바코드로 연도 순서 판별	발동 가능 이미지 0장
느슨한 꼬리 패턴 추가	64.5% → 63.8%	세 파이프라인 다수결	79.8% → 69.2%

합성·회귀 테스트를 통과하고도 홀드아웃에서 떨어진 변경이 두 건 있었다. 이후 모든 채택 판정을 설계에 쓰지 않은 홀드아웃의 부분점수로만 내렸다.

1. 어떤 숫자가 소비기한인가 — 판별 규칙

설계 의도



이것이 과제의 본질이다. 상품 뒷면에는 제조일자·바코드·품목보고번호·전화번호·영양성분이 함께 인쇄돼 있다. 날짜 형태의 숫자를 찾는 것만으로는 부족하고, **그중 무엇이 소비기한인지를 가려야 한다.**

OCR 은 2022 와 02.14 를 다른 줄로 끊는다. 인접 조각을 이어 붙이는 것이 이를 복구한다 — 보조 경로에서는 박스 좌표로 같은 일을 하며, **비용 0에 48% → 68%**로 단일 최대 개선이었다.

규칙	실측 근거
4자리 연도 우선	정밀도 99.2% (2자리는 79.4%)
제조/소비 쌍이면 낮은 날짜	해당 사례 전부에서 성립
9자리+ 숫자 내부 매치 차단	품목보고번호 20130628332176 오탐
미래성 필터 금지	정답에 2020~2022년 과거 날짜 다수
부분 필드 출력	연·월·일 독립 채점 — 버리지 않고 회수

2. 제한된 CPU 환경에서의 속도·오탐 최적화

최적화 전략

전략	근거가 된 실측
싼 경로로 90%를 끝낸다 2계층 구조	주력 0.37초 / 보조 2.19초. 보조가 필요한 이미지는 전체의 5%
인식을 덜 부른다 박스 사전 필터(보조)	rec 가 보조 경로 비용의 80.9%, 날짜가 든 박스는 0.63%
해상도를 낮춘다 960 → 640px (보조)	위로만 시험한 것이 실수였다. 내리자 정확도 +8.8%p, 비용 62%
실패한 것만 다시 본다 적응형 재시도	상시 전처리는 유의성 없음(p=0.201). 성공한 이미지를 망가뜨린다
torch 를 실행하지 않는다 전 경로 ONNX	임포트만 해도 2.76 → 5.88초/장. paddle 과 OpenMP 스레드를 다룬다

구성	장당	500장	제한 대비
torch 임포트 시 (참고)	5.88초	2,939초	122% ×
보조 경로 단독	2.19초	1,096초	46%
주력 경로 단독	0.37초	184초	8%
최종 구성	0.53초	267초	11%

마지막 전략이 가장 값비쌌던 함정이다.

set_num_threads(1) · KMP_BLOCKTIME=0 · OMP_WAIT_POLICY=PASSIVE 를 모두 시도했지만 6초대에서 내려오지 않아 500장이 제한을 넘겼다. 가중치를 ONNX 로 내 보내 torch 를 제거하는 것이 해법이였다(변환 전후 박스 IoU 1.000 확인). 후보였던 EasyOCR 파이프라인도 같은 이유로 기각했다.

정확도를 올렸는데 속도가 4배 빨라졌다 — 더 정확한 엔진이 재시도를 덜 유발하기 때문이다. 채점 명령 실측 188장: 163초 = 0.865초/장.

3. 데이터 직접 라벨링

가산점 증빙

배포 데이터 3,352장은 정답 라벨이 전혀 없다. 자체 도구 (label/index.html) 를 만들어 직접 판독·검수한 383장으로 설계하고 검증했다. 이 라벨이 없었다면 세 파이프라인 중 어느 것이 나옴지 판단할 방법 자체가 없었다 — 실제로 최종 채택된 구성은 자체 평가("값이 채워진 행 수")만으로는 열세로 보이던 쪽이었다.

집합	장수	용도
튜닝셋	137	규칙 설계·파라미터 결정
1차 홀드아웃	48	연도 후행형 버그 발견
2차 홀드아웃	198	최종 성능 판정

라벨링 기준은 문서로 먼저 고정했다 — 소비기한과 제조일자가 함께 인쇄되면 낮은 쪽, 판독 불가·중의적인 2장은 제외.

4. 추후 활용 계획 및 확장성

활용 전략

적용 도메인	운영 구조	이 아키텍처가 맞는 이유
편의점·마트 유통기한 관리 진열대를 촬영하면 임박 상품 자동 집계	온디바이스(모바일 CPU). 주력만 쓰면 30MB·0.37초/장 — 서버 왕복·통신비 0	GPU 를 전제하지 않아 그대로 단말에 올라간다. 성능이 낮은 단말은 보조 경로만 꺼서 축소 운용
푸드뱅크 기부 식품 선별 기부 물품의 잔여 기한을 일괄 판정	배치 서버. 단일 프로세스 시간당 약 6,800장, 코어 수만큼 병렬 확장	필드별 부분 출력(NONE-08-25)이 사람 검수 대상을 좁혀 준다
물류창고 입고출고 자동화 입고 시 기한을 읽어 선입선출 배치	엣지 게이트웨이 + 컨베이어 카메라	확장 경로는 엔진 교체다. 주력 엔진과 판별 규칙을 분리해 두어 엔진만 갈 아끼우면 된다