


[DScover_카피바라] 아키텍처 구조도 · 설계 요약서

제3회 ITDA 연합학술제 · OCR 기반 상품 소비기한 정보 추출

1. 전체 파이프라인 아키텍처 구조도

소비기한 OCR 추론 파이프라인 (predict.ipynb)

itda3-dscover-capybara | DScover_카피바라 | 3단계 구조



2. 설계 논리 및 최적화·활용 전략

2.1 모델/규칙 설계 의도 및 기술 선택의 논리적 이유

상품 뒷면 이미지에는 소비기한 외에도 제조일자, 바코드, 품목보고번호, 전화번호, 영양성분, LOT 번호 등 낱자와 혼동될 수 있는 숫자가 다수 공존한다. 따라서 "낱자 형식을 찾는 문제"와 "그 중 소비기한을 가려내는 문제"를 분리해서 설계했다.

- ① OCR 엔진은 대화가 허용한 오픈소스 사전학습 가중치 중 EasyOCR(ko+en) 을 선택했다. 한글 키워드(소비기한/유통기한/까지/제조)와 숫자를 함께 인식해야 후속 스코어링이 가능하며, 오프라인 가중치 확보(GitHub Release Asset)의 재현 가능성도 직접 검증했다.
- ② 낱자 후보는 정규식으로 형식을 먼저 걸러내고(YYYY.MM.DD/-/,/년월일 및 구분자 없는 YYYYMMDD, 콤마 오인식 보정 포함), 연/월/일 유효 범위(2020~2035, 1~12, 1~31)를 검증해 명백한 바코드·보고번호·전화번호를 1차로 배제한다.
- ③ 같은 형식의 후보가 여러 개 남을 경우, 같은 줄/인접 줄의 문맥에 소비기한·유통기한·까지 가 있으면 가점, 제조일자·제조·LOT 가 있으면 감점하는 규칙 기반 스코어링으로 최종 값을 선택한다. 이는 학습 데이터 없이도(비지도) 참가자가 직접 정의한 라벨링 규칙을 적용한 것으로, 예선 라벨 없는 3,352장 데이터셋의 특성에 맞춘 설계다.
- ④ 근거(키워드/형식)가 불충분하면 억지로 추정하지 않고 NONE을 반환하는 정밀도 우선 전략을 택했다. 오답을 자신 있게 제시하는 것보다, 근거가 있을 때만 값을 내는 편이 실제 산업 적용 시 더 신뢰할 수 있는 시스템이라고 판단했다.

2.2 제한된 CPU 환경에서의 속도/오탐 최적화 전략

이미지를 고해상도(800px+)로 EasyOCR 전체 파이프라인(CRAFT 검출+인식)에 넣으면 인식률은 높지만 3,352장을 2,400초 안에 처리할 수 없고, 축소하면 빨라지지만 저대비·옴보싱 각인 숫자의 인식률이 급격히 떨어진다. 이 상충을 해결하는 과정에서 로컬(2-core) 프로파일링과 실제 채점 환경(4-core)의 결론이 서로 달랐던 경험을 했고, 최종적으로는 실제 4-core 환경에서 전체 3,352장을 완주시켜 확정된 3단계 구조를 채택했다.

- ① 2회의 재설계 — 로컬 추정과 실제 환경 실측이 어긋난 경험: 처음에는 classical CV 저비용 1단계 후 실패 시에만 EasyOCR을 호출하는 캐스케이드였으나, 로컬 2-core 프로파일링(150~60장)에서 1단계 적중률이 8~10%에 불과한데 처리 시간은 2단계와 비슷해(1.6~1.7초/장) 이를 제거하고 EasyOCR 단일 패스로 단순화했었다. 그런데 실제 4-core Codespaces에서 전체 3,352장을 실행하니 결론이 뒤집혔다: classical CV 후보를 34→16개로 줄이고 실패 시 이미지 전체가 아닌 상위 6개만 재인식하는 가벼운 버전이 3,352장 전체를 1,475.5초(예산 2,250초의 66%)에 처리하고 정답 378장(11.28%)을 기록해, 단일 패스(9.37%, 54%만 처리)보다 우수했다. 로컬 프로파일링만으로 실제 채점 환경의 결론을 확정하지 않기로 한 이유다.
- ② 3단계 구조로 재통합: 위 방식은 classical CV가 애초에 후보를 놓친 이미지는 구조적으로 복구 못하고(로컬 재현에서 실패 사례 확인), 예산의 34%가 그대로 남는 한계도 있었다. 1단계(후보≤16개 배치 인식)·2단계(실패 시 상위 6개만 재인식)는 항상 수행하고, 둘 다 실패한 이미지에만 3단계로 CLAHE + EasyOCR 전체 파이프라인을 재시도한다. "워커 1개가 이미지 1장에 쓸 여유시간"=(남은시간×N_WORKERS)/남은이미지 이 클수록 큰 canvas(550px), 작을수록 작은 canvas(250px)를 쓰고 없으면 생략한다. 로컬 재현에서 3단계가 실패 사례를 복구하는 것(성공 17→30/100장)을 확인했다.
- ③ 명시적 안전 마진: 시간이 남으면 정확도에 재투자하되, 'SAFETY_MARGIN_SEC'=250초(2,400초 타임아웃 대비)는 3단계가 아무리 시간을 더 쓰려 해도 절대 침범하지 않는 하한선으로 고정했다. 극단적으로 짧은 예산(로컬 40초)으로 강제 테스트해도 넘기지 않고 완주하는 것을 확인했다 — 정확도 개선이 "시간 초과로 정량 0점"이라는 최악의 결과로 이어지지 않게 하는 구조적 장치다.
- ④ 스레드 병렬화 + 조각 스티칭 + 달력 유효성 검증: 4-Core 환경에 맞춰 최대 4개 워커 스레드(ThreadPoolExecutor)를 쓰고 BLAS/torch 스레드는 1개로 고정했다(multiprocessing.Pool(fork)은 Jupyter 커널에서 락 획득 실패로 멈추는 사례가 있어 교체). 여러 박스로 쪼개 인식된 낱자는 좌표 기반으로 이어붙이고(stitching), 낱자 후보는 달력 유효성 검사(datetime.date)로 "2026-02-30"같은 실존하지 않는 낱자를 추가로 제거한다.

2.3 사회적·산업적 활용 가치 및 차별점

국내 가공식품 반품·폐기 규모는 연간 약 40만 톤·5,800억 원이며, 32%는 "유통기한 내 미판매"가 원인이다. 주목할 점은 반품 식품의 44%가 곧바로 구호기관(푸드뱅크 등)으로 기증된다는 것인데, 브랜드·포맷이 제각각인 기증 물품을 육안으로 확인하는 과정이 병목이 된다(식품저널, 2024). 본 파이프라인은 이 1차 스크리닝을 자동화할 수 있다.

기존 대안과 비교하면 차별점이 뚜렷하다. ① CU/GS25/이마트24 등 국내 편의점의 AI 재고관리는 판매 데이터 기반 수요예측·발주 자동화에 집중되어 있어, 실제 라벨의 소비기한을 광학적으로 읽어내는 기능 자체가 없다. ② Scandit 등 해외 상용 OCR 유통기한 솔루션은 최대 40% 폐기 감소 효과를 보고하지만, 대형 유통업체 대상의 유료 엔터프라이즈 SaaS다. ③ 학계 선행연구(모바일 + Firebase ML Kit + Google Cloud Vision, 2024)도 클라우드 API에 의존해 완전한 오프라인 동작이 불가능하고 이미지 1장마다 호출 비용이 발생한다. 반면 본 파이프라인은 전액 오프라인·CPU 전용·오픈소스 기반이라 인터넷 인프라나 예산이 부족한 조직(푸드뱅크, 지역아동센터, 재해 구호 현장, 소규모 자영업)에서도 라이선스 비용 없이 그대로 쓸 수 있고, 이미지가 기기 밖으로 나가지 않아 재고 현황 유출 위험도 없다.

본선에서는 (1) 푸드뱅크·지역아동센터 기증 물품 1차 스크리닝, (2) 소매 재고관리 연동 임박상품 알림으로 구체화하고, 정규식·스코어링 가중치는 직접 수집한 예외 케이스로 계속 튜닝할 계획이다. [출처: 식품저널(2024); Scandit; MDPI(2024)]