


[DScover_카피바라] 아키텍처 구조도 · 설계 요약서

제3회 ITDA 연합학술제 · OCR 기반 상품 소비기한 정보 추출

1. 전체 파이프라인 아키텍처 구조도

소비기한 OCR 추론 파이프라인 (predict.ipynb)

DScover_카피바라 | A. 인식 3단계 + B. 날짜 해석 4단계



2. 설계 논리 및 최적화·활용 전략

2.1 모델/규칙 설계 의도 및 기술 선택의 논리적 이유

상품 뒷면 이미지에는 소비기한 외에도 제조일자, 바코드, 품목보고번호, 전화번호, 영양성분, LOT 번호 등 날짜와 혼동될 수 있는 숫자가 다수 공존한다. 따라서 "날짜 형식을 찾는 문제"와 "그 중 소비기한을 가려내는 문제"를 분리해서 설계했다.

- ① OCR 엔진은 대회가 허용한 오픈소스 사전학습 가중치 중 EasyOCR(ko+en)을 선택했다. 한글 키워드(소비기한/유통기한/까지/제조)와 숫자를 함께 인식해야 후속 스코어링이 가능하며, 오프라인 가중치 확보(GitHub Release Asset)의 재현 가능성도 직접 검증했다.
- ② 날짜 후보는 정규식으로 형식을 먼저 걸러내고(YYYY.MM.DD/-/,/년월일 및 구분자 없는 YYYYMMDD, 콤마 오인식 보정 포함), 연/월/일 유효 범위(2020~2035, 1~12, 1~31)를 검증해 명백한 바코드·보고번호·전화번호를 1차로 배제한다.
- ③ 같은 형식의 후보가 여러 개 남을 경우, 같은 줄/인접 줄의 문맥에 소비기한·유통기한·까지 가 있으면 가점, 제조일자·제조·LOT 가 있으면 감점하는 규칙 기반 스코어링으로 최종 값을 선택한다. 이는 학습 데이터 없이도(비지도) 참가자가 직접 정의한 라벨링 규칙을 적용한 것으로, 예선 라벨 없는 3,352장 데이터셋의 특성에 맞춘 설계다.
- ④ 근거(키워드/형식)가 불충분하면 역지로 추정하지 않고 NONE을 반환하는 정밀도 우선 전략을 택했다. 표본 검수 결과 20장 중 5장(25%)이 연-월-일이 아닌 해외 제품 표기(예: EXP. DATE: 11/05/2021, DEC-28-2021)였는데, 국가를 추정하지 않고 값 자체로 순서를 역산하도록 확장했다 — 두 숫자 중 하나가 13 이상이면 그제 일(day)로 확정되어 유럽식·미국식 모두 국가 판별 없이 커버되고, 둘 다 1~12라 순서를 알 수 없으면 연도만 채택하고 월/일은 NONE으로 남긴다(예: 2021-NONE-NONE). 이 로직은 500장 실제 실험에서 5건 발동을 CSV로 직접 확인했다. 그래도 애매하면 EAN-13 체크섬을 통과한 바코드의 GS1 국가 접두어로 표기 순서를 최후 힌트로만 참고한다(기존 확정 로직은 절대 덮어쓰지 않으며, 단위테스트 41종으로 검증). 완전히 인식하지 못하면 'NONE-NONE-NONE'을 반환하는데, 이는 운영진 공지 문구를 따른 것으로 제출 안내서 스키마 표 예시(단일 'NONE')와 다르다는 점을 인지하고 있으며, 팀이 문서화한 규칙 기준으로 애매한 값을 판단한다는 안내에 따라 이 문서를 그 근거로 남긴다.
- ⑤ 개선점은 추측이 아니라 실패 사례 전수 조사로 찾았다: 실제 NONE 이었던 84장의 OCR 출력을 모두 뜯어보고 원본을 눈으로 확인한 결과 79장(94%)은 날짜 문자열 자체가 안 잡히는 검출 커버리지 문제였고, 나머지에서 '읽었는데 파서가 버리는' 두 유형을 찾아 반영했다 — 2자리 연도(22.10.21; 구분자·연도범위·달력 검증을 다 통과하고 4자리 패턴이 없을 때만, 뒤에 시:분이 붙으면 생산 타임스탬프로 보고 제외)와 필드 단위 부분 구제(2025.05.0 → 2025-05-NONE; 필드별 부분점수이므로 검증된 필드까지만 회수, 깨진 필드 오른쪽은 자릿수 밀림 위험으로 불신). 키워드 점수를 근거 강도보다 항상 우선하는데, 반대로 하면 제조일자가 소비기한을 밀어내는

회귀가 생기는 것을 테스트로 확인했다. 효과가 없어 기각한 것도 남긴다: dot-matrix 각인용 모폴로지 전처리하는 실패 24장 중 복구 0장이었다. 검증은 단위테스트 41종과 실제 103장 중단 비교(OCR 1회 캐시 후 변경 전/후 파서 비교)로 했고 사라지거나 바뀐 값 0장, 새로 생긴 값 8장이었다. 여기서 예측한 '359장 실패분 중 약 30장 복구'는 최종 코드로 500장을 재실행해 정확히 30장(141 → 171장) 복구로 확인했다.

2.2 제한된 CPU 환경에서의 속도/오탐 최적화 전략

이미지를 고해상도(800px+)로 EasyOCR 전체 파이프라인(CRAFT 검출+인식)에 넣으면 인식률은 높지만 3,352장을 2,400초 안에 처리할 수 없고, 축소하면 빨라지지만 저대비·엠보싱 각인 숫자의 인식률이 급격히 떨어진다. 이 상충을 해결하는 과정에서 로컬(2-core) 프로파일링과 실제 채점 환경(4-core)의 결론이 서로 달랐던 경험을 했고, 최종적으로는 실제 4-core 환경에서 전체 3,352장을 완주시켜 확정된 3단계 구조를 채택했다. 아래 최적화들은 속도뿐 아니라 오탐 억제도 겨냥한다 — 후보 박스 수를 제한(①)하면 연산량이 줄면서 동시에 바코드·전화번호 영역을 스캔할 기회 자체가 줄어 오탐 소스가 구조적으로 차단된다.

- ① 2회의 재설계 — 로컬 추정과 실제 환경 실측이 어긋난 경험: 처음에는 classical CV 저비용 1단계 후 실패 시에만 EasyOCR을 호출하는 캐스케이드였으나, 로컬 2-core 프로파일링(150·60장)에서 1단계 적중률이 8~10%에 불과한데 처리 시간은 2단계와 비슷해(1.6~1.7초/장) 이를 제거하고 EasyOCR 단일 패스로 단순화했었다. 그런데 실제 4-core Codespaces에서 전체 3,352장을 실행하니 결론이 뒤집혔다: classical CV 후보를 34→16개로 줄이고 실패 시 이미지 전체가 아닌 상위 6개만 재인식하는 가벼운 버전이 3,352장 전체를 1,475.5초(예산 2,250초의 66%)에 처리하고 정답 378장(11.28%)을 기록해, 단일 패스(9.37%, 54%만 처리)보다 우수했다. 로컬 프로파일링만으로 실제 채점 환경의 결론을 확정하지 않기로 한 이유다.
- ② 3단계 구조로 재통합: 위 방식은 classical CV가 애초에 후보를 놓친 이미지는 구조적으로 복구 못하고, 예산의 34%가 그대로 남는 한계도 있었다. 1단계(후보≤16개 배치 인식)·2단계(실패 시 상위 6개만 재인식)는 항상 수행하고, 둘 다 실패한 이미지에만 3단계로 CLAHE + EasyOCR 전체 파이프라인을 재시도한다. "워커 1개가 이미지 1장에 쓸 여유시간"=(남은시간×N_WORKERS)/남은이미지 이 클수록 큰 canvas(550px), 작을수록 작은 canvas(250px)를 쓰고 없으면 생략한다. 로컬 100장 재현(17→30장)으로 먼저 확인한 뒤 실제 4-core 환경 전체 3,352장으로 최종 검증했다 — 1,892.8초에 완료(안전마진 미침범), 정답 407장(12.14%)으로 1·2단계만 쓴 버전(378장, 11.28%)보다 29장 더 복구했다. 3단계 canvas 선택 공식이 이미지 수에 반비례해 실제 평가 규모(500장)에서는 장당 여유시간이 약 6.7배 커지므로, 500장을 무작위 추출해 채점 명령을 그대로 재실행해 재검증했다 — 최종 코드 기준 938.4초 완료(2,400초 대비 약 1,460초 여유), 값이 채워진 행 171/500장(34.2%)으로, 이 수치가 실제 채점 조건에 가장 가깝다.
- ③ 명시적 안전 마진: 시간이 남으면 정확도에 재투자하되, `SAFETY\_MARGIN\_SEC`=250초(2,400초 타임아웃 대비)는 3단계가 아무리 시간을 더 쓰려 해도 절대 침범하지 않는 하한선으로 고정했다. 극단적으로 짧은 예산(로컬 40초)으로 강제 테스트해도 넘기지 않고 완주하는 것을 확인했다 — 정확도 개선이 "시간 초과로 정량 0점"이라는 최악의 결과로 이어지지 않게 하는 구조적 장치다.
- ④ 스레드 병렬화 + 조각 스티칭 + 달력 유효성 검증(오탐 억제): 4-Core 환경에 맞춰 최대 4개 워커 스레드(ThreadPoolExecutor)를 쓰고 BLAS/torch 스레드는 1개로 고정했다(multiprocessing.Pool(fork)은 Jupyter 커널에서 락 획득 실패로 멈추는 사례가 있어 교체). 여러 박스로 쪼개 인식된 날짜는 좌표 기반으로 이어붙이고(stitching), 달력 유효성 검사(datetime.date)로 "2026-02-30"같은 형식만 맞는 오탐 날짜를 추가로 제거한다.

2.3 추후 활용 계획 및 확장성

국내 가공식품 반품·폐기 규모는 연간 약 40만 톤·5,800억 원이며, 반품 식품의 44%가 곧바로 구호기관(푸드뱅크 등)에 기증되지만 브랜드·포맷이 제각각인 물품을 육안으로 확인하는 과정이 병목이 된다(식품저널, 2024). 본 파이프라인은 이 1차 스크리닝 자동화를 목표로 하며, 아래와 같이 단기·중기·장기로 나눠 고도화할 계획이다.

- ① 단기(제출 후~본선 준비): 실제 4-core 채점 환경에서 3,352장 전체(1,892.8초, 12.14%)와 실제 평가 규모인 500장(최종 코드 938.4초, 34.2%) 두 스케일 모두 검증을 완료했다. 다음 단계로 NONE으로 남은 이미지를 팀이 직접 라벨링해 정규식·키워드 스코어링 가중치와 `TIER3\_CANVAS\_SCHEDULE` 임계값을 데이터 기반으로 재조정한다.
- ② 중기: 푸드뱅크·지역아동센터 기증 물품 1차 스크리닝, 소매 재고관리 시스템과 연동한 임박상품 알림에 파일럿으로 투입하고, 파일럿에서 쌓이는 처리 로그(어떤 라벨 형태에서 NONE이 많은지)를 다시 규칙 튜닝에 반영하는 피드백 루프를 구축한다.
- ③ 장기 확장성: 현재 구조는 후보검출(classical CV) → 인식(EasyOCR) → 스코어링(규칙) 3개 컴포넌트가 느슨하게 분리돼 있어, 라벨 데이터가 쌓이면 후보검출·스코어링만 경량 학습 기반 모델로 교체하는 점진적 고도화가 가능하다. 오프라인·CPU 전용 특성을 유지한 채 API로 감싸 다른 재고·기부관리 시스템에 임베드하는 것도 자연스러운 확장 경로다.

이 경로가 실질적인 이유는 차별점에 있다: 국내 편의점 AI 재고관리는 수요예측·발주 자동화에 집중돼 소비기한을 광학적으로 읽는 기능이 없고, Scandit 등 해외 상용 솔루션은 대형 유통업체 대상 유료 SaaS이며, 학계 선행연구(모바일+Firebase ML Kit+Google Cloud Vision, 2024)는 클라우드 API 의존으로 완전 오프라인 동작이 불가능하다. 본 파이프라인은 전액 오프라인·CPU 전용·오픈소스라 인터넷·예산이 부족한 조직에서도 비용 없이 그대로 확장해 쓸 수 있다. [출처: 식품저널(2024); Scandit; MDPI(2024)]