

[DScover_카피바라] 아키텍처 구조도 · 설계 요약서

제3회 ITDA 연합학술제 · OCR 기반 상품 소비기한 정보 추출

1. 전체 파이프라인 아키텍처 구조도

소비기한 OCR 추론 파이프라인

predict.ipynb · 3단계 구조 · ThreadPoolExecutor

1. 입력 레이어

입력 이미지
(ITDA_INPUT_DIR)

2. 핵심 병렬 파이프라인 (ThreadPoolExecutor)

1단계: Classical CV 후보 검출(516개)
+ EasyOCR 배치 인식 (CRAFT 생략)

1단계에서
날짜 발견?

아니오

2단계: 상위 6개 후보만
CLARE 대비보정 재인식

2단계에서
날짜 발견?

아니오

시간 여유 있음?
(남은시간 계산)

아니오(부족)

명시적 안전 마진 적용
SAFETY_MARGIN_SEC=250초

3단계: 이미지 전체 재검출
canvas 250~550px 적용형 적용

3. 시간 기반 동적 스케줄링

4. 검증 및 스코어링 레이어

정규식 + 키워드 스코어링
+ 달력 유효성 검증 (datetime)

5. 출력 레이어

최종 값 반환
(YYYY, MM, DD 또는 NONE)

submission.csv
(최종 제출 파일)

2. 설계 논리 및 최적화·활용 전략

2.1 모델/규칙 설계 의도 및 기술 선택의 논리적 이유

상품 뒷면 이미지에 소비기한 외에도 제조일자, 바코드, 품목보고번호, 전화번호, 영양성분, LOT 번호 등 낱자와 혼동될 수 있는 숫자가 다수 공존한다. 따라서 "낱자 형식을 찾는 문제"와 "그 중 소비기한을 가려내는 문제"를 분리해서 설계했다.

- ① OCR 엔진은 대화가 허용한 오픈소스 사전학습 가중치 중 EasyOCR(ko+en) 을 선택했다. 한글 키워드(소비기한/유통기한/까지/제조)와 숫자를 함께 인식해야 후속 스코어링이 가능하며, 오프라인 가중치 확보(GitHub Release Asset)의 재현 가능성도 직접 검증했다.
- ② 낱자 후보는 정규식으로 형식을 먼저 걸러내고(YYYY.MM.DD/-/,/년월일 및 구분자 없는 YYYYMMDD, 콤마 오인식 보장 포함), 연/월/일 유효 범위(2020~2035, 1~12, 1~31)를 검증해 명백한 바코드·보고번호·전화번호를 1차로 배제한다.
- ③ 같은 형식의 후보가 여러 개 남을 경우, 같은 줄/인접 줄의 문맥에 소비기한·유통기한·까지 가 있으면 가점, 제조일자·제조·LOT 가 있으면 감점하는 규칙 기반 스코어링으로 최종 값을 선택한다. 이는 학습 데이터 없이도(비지도) 참가자가 직접 정의한 라벨링 규칙을 적용한 것으로, 예선 라벨 없는 3,352장 데이터셋의 특성에 맞춘 설계다.
- ④ 근거(키워드/형식)가 불충분하면 억지로 추정하지 않고 NONE을 반환하는 정밀도 우선 전략을 택했다. 오답을 자신 있게 제시하는 것보다, 근거가 있을 때만 값을 내는 편이 실제 산업 적용 시 더 신뢰할 수 있는 시스템이라고 판단했다.

2.2 제한된 CPU 환경에서의 속도/오탐 최적화 전략

이미지를 고해상도(800px+)로 EasyOCR 전체 파이프라인(CRAFT 검출+인식)에 넣으면 인식률은 높지만 3,352장을 2,400초 안에 처리할 수 없고, 축소하면 빨라지지만 저대비·엠보싱 각인 숫자의 인식률이 급격히 떨어진다. 이 상충을 해결하는 과정에서 로컬(2-core) 프로파일링과 실제 채점 환경(4-core)의 결론이 서로 달랐던 경험을 했고, 최종적으로는 실제 4-core 환경에서 전체 3,352장을 완주시켜 확정한 3단계 구조를 채택했다. 아래 최적화들은 속도뿐 아니라 오탐 억제도 겨냥한다 — 후보 박스 수를 제한(①)하면 연산량이 줄면서 동시에 바코드·전화번호 영역을 스캔할 기회 자체가 줄어 오탐 소스가 구조적으로 차단된다.

- ① 2회의 재설계 — 로컬 추정과 실제 환경 실측이 어긋난 경험: 처음에는 classical CV 저비용 1단계 후 실패 시에만 EasyOCR을 호출하는 캐스케이드였으나, 로컬 2-core 프로파일링(150~60장)에서 1단계 적중률이 8~10%에 불과한데 처리 시간은 2단계와 비슷해(1.6~1.7초/장) 이를 제거하고 EasyOCR 단일 패스로 단순화했다. 그런데 실제 4-core Codespaces에서 전체 3,352장을 실행하니 결론이 뒤집혔다: classical CV 후보를 34→16개로 줄이고 실패 시 이미지 전체가 아닌 상위 6개만 재인식하는 가벼운 버전이 3,352장 전체를 1,475.5초(예산 2,250초의 66%)에 처리하고 정답 378장(11.28%)을 기록해, 단일 패스(9.37%, 54%만 처리)보다 우수했다. 로컬 프로파일링만으로 실제 채점 환경의 결론을 확정하지 않기로 한 이유다.
- ② 3단계 구조로 재통합: 위 방식은 classical CV가 애초에 후보를 놓친 이미지는 구조적으로 복구 못하고, 예산의 34%가 그대로 남는 한계도 있었다. 1단계(후보≤16개 배치 인식)·2단계(실패 시 상위 6개만 재인식)는 항상 수행하고, 둘 다 실패한 이미지에만 3단계로 CLAHE + EasyOCR 전체 파이프라인을 재시도한다. "위커 1개가 이미지 1장에 쓸 여유시간"=(남은시간×N_WORKERS)/남은이미지 이 클수록 큰 canvas(550px), 작을수록 작은 canvas(250px)를 쓰고 없으면 생략한다. 로컬 100장 재현(17→30장)으로 먼저 확인한 뒤 실제 4-core 환경 전체 3,352장으로 최종 검증했다 — 1,892.8초에 완료(안전마진 미침범), 정답 407장(12.14%)으로 1·2단계만 쓴 버전(378장, 11.28%)보다 29장 더 복구했다.
- ③ 명시적 안전 마진: 시간이 남으면 정확도에 재투자하되, 'SAFETY_MARGIN_SEC'=250초(2,400초 타임아웃 대비)는 3단계가 아무리 시간을 더 쓰려 해도 절대 침범하지 않는 하한선으로 고정했다. 극단적으로 짧은 예산(로컬 40초)으로 강제 테스트해도 넘기지 않고 완주하는 것을 확인했다 — 정확도 개선이 "시간 초과로 정량 0점"이라는 최악의 결과로 이어지지 않게 하는 구조적 장치다.
- ④ 스레드 병렬화 + 조각 스티칭 + 달력 유효성 검증(오탐 억제): 4-Core 환경에 맞춰 최대 4개 위커 스레드(ThreadPoolExecutor)를 쓰고 BLAS/torch 스레드는 1개로 고정했다(multiprocessing.Pool(fork)은 Jupyter 커널에서 락 획득 실패로 멈추는 사례가 있어 교체). 여러 박스로 쪼개 인식된 낱자는 좌표 기반으로 이어붙이고(stitching), 달력 유효성 검사(datetime.date)로 "2026-02-30"같은 형식만 맞는 오탐 낱자를 추가로 제거한다.

2.3 추후 활용 계획 및 확장성

국내 가공식품 반품·폐기 규모는 연간 약 40만 톤·5,800억 원이며, 반품 식품의 44%가 곧바로 구호기관(푸드뱅크 등)에 기증되지만 브랜드·포맷이 제각각인 물품을 육안으로 확인하는 과정이 병목이 된다(식품저널, 2024). 본 파이프라인은 이 1차 스크리닝 자동화를 목표로 하며, 아래와 같이 단기·중기·장기로 나눠 고도화할 계획이다.

- ① 단기(제출 후~본선 준비): 실제 4-core 채점 환경 전체 3,352장 검증은 완료했다(1,892.8초, 정답 407장·12.14%). 다음 단계로 이번에 NONE으로 남은 약 2,945장을 팀이 직접 라벨링해 정규식·키워드 스코어링 가중치와 'TIER3_CANVAS_SCHEDULE' 임계값을 데이터 기반으로 재조정한다.
- ② 중기: 푸드뱅크·지역아동센터 기증 물품 1차 스크리닝, 소매 재고관리 시스템과 연동한 임박상품 알림에 파일럿으로 투입하고, 파일럿에서 쌓이는 처리 로그(어떤 라벨 형태에서 NONE이 많은지)를 다시 규칙 튜닝에 반영하는 피드백 루프를 구축한다.
- ③ 장기 확장성: 현재 구조는 후보검출(classical CV) → 인식(EasyOCR) → 스코어링(규칙) 3개 컴포넌트가 느슨하게 분리돼 있어, 라벨 데이터가 쌓이면 후보검출·스코어링만 경량 학습 기반 모델로 교체하는 점진적 고도화가 가능하다. 오프라인·CPU 전용 특성을 유지한 채 API로 감싸 다른 재고·기부관리 시스템에 임베드하는 것도 자연스러운 확장 경로다.

이 경로가 실질적인 이유는 차별점에 있다: 국내 편의점 AI 재고관리는 수요예측·발주 자동화에 집중돼 소비기한을 광학적으로 읽는 기능이 없고, Scandit 등 해외 상용 솔루션은 대형 유통업체 대상 유료 SaaS이며, 학계 선행연구(모바일+Firebase ML Kit+Google Cloud Vision, 2024)는 클라우드 API 의존으로 완전 오프라인 동작이 불가능하다. 본 파이프라인은 전액 오프라인·CPU 전용·오픈소스라 인터넷·예산이 부족한 조직에서도 비용 없이 그대로 확장해 쓸 수 있다. [출처: 식품저널(2024); Scandit; MDPI(2024)]