


상품 뒷면 이미지 소비기한 추출: 파이프라인 아키텍처

CPU 단독 40분 제한을 기준으로, 비용이 저렴한 칸에서 대부분을 처리하고 실패한 이미지에만 비용이 더 큰 칸을 계산 제3회 ITDA 연합학술제 본선 식으로 적용했다. [DScover] 카피바라 직접 라벨링한 828장으로 설계·검증했으며, 최종 성능은 한 번도 설계에 사용하지 않은 248장에서 측정했다. 2026-10-03



| 단계            | 하는 일                                   | 이렇게 한 근거 (실측)                                                                      |
|---------------|----------------------------------------|------------------------------------------------------------------------------------|
| RapidOCR      | PP-OCRv6 det + rec 를 ONNX 로 한 번에. 30MB | 엔진 세대가 성능을 갈랐다. 같은 평가셋에서 v3+v4 조합 66.8%, v6 조합 79.8%                               |
| 재시도 계단        | 실패한 이미지에만 det medium → CLAHE 를 차례로 적용  | det medium 을 처음부터 사용하면 맞았던 2장이 망가진다. 실패분에만 걸면 그 회귀가 사라져 최종 판정에서 악화 0장              |
| 온전한 날짜만 성공 처리 | 반쪽짜리는 모아 두었다가 모든 칸이 실패했을 때만 사용         | 부분 결과가 계단을 멈춰 세워, 다음 칸이 2021.11.19 를 읽을 수 있는데도 NONE-11-19 에 머물렀다. 이 한 줄이 가장 큰 기여   |
| 박스 필터         | rec 없이 계산되는 영상 특징으로 상위 K개만 통과          | rec 가 보조 경로 비용의 80.9%를 차지하는데, det 가 제안한 전체 박스 26,499개 중 날짜가 파싱되는 것은 0.63%(167개)뿐이다 |

|                               |                                  |                                  |                                |
|-------------------------------|----------------------------------|----------------------------------|--------------------------------|
| 92.3%<br>필드 정확도<br>(미사용 248장) | 1.20초<br>장당 처리시간<br>(500장 순차 실측) | 26%<br>500장 614초<br>제한 2,400초 대비 | 828장<br>직접 라벨링<br>(배포분의 24.7%) |
|-------------------------------|----------------------------------|----------------------------------|--------------------------------|

필드 정확도: 연·월·일을 각각 독립 채점해 맞힌 필드 수 ÷ 전체 필드 수(248장 × 3필드 = 744). 운영진 채점 방식(부분점수)과 동일하며 95% 신뢰구간은 90.2~94.0%. 장당 처리시간: 제출 노트북과 같은 단일 프로세스 순차 루프로 측정했다.

본선 라운드에서 무엇이 얼마나 기여했는가 개선 근거

기여도는 라벨 580장에서 하나씩 붙여 가며 측정했다(기준선 = 예선 구성 92.4%). 이 표본은 오답을 직접 들여다봤으므로 낙관 편향이 있다. 절대 수치는 미사용 248장을 쓴다.

| 불인 것                 | 필드 정확도 (580장) | 기여     | 왜 이것을 붙였는가                                                                                |
|----------------------|---------------|--------|-------------------------------------------------------------------------------------------|
| 부분 결과가 계단을 막던 버그     | 92.9%         | +0.5%p | OCR 이 정확히 읽은 날짜를 반쪽짜리 결과가 가로막고 있었다                                                        |
| 규칙 보강 3종             | 93.9%         | +1.0%p | 01 SEP 2023 · JUL 22 21 형식 추가, 202512.20 구분자 결손 처리, 2026.08 + 22:14 에서 시각이 일(日)로 먹히던 것 차단 |
| CLAHE 재시도 칸          | 94.1%         | +0.2%p | 전처리 11종 중 유일하게 남은 것. 회수는 23장 중 3장뿐이었다                                                     |
| 인식기를 바꾼 칸 (한국어 → 영문) | —             | +1.1%p | 주력 인식기가 중국어 모델이라 한글을 못 읽는다. 한글이 날짜에 붙어 있으면 (유통2023.01.05 까지) 날짜까지 깨진다. 이 수치는 미사용 표본에서 잦 것 |
| 도트 판독기 (직접 학습, CTC)  | —             | +0.2%p | 일반 인식기는 26.08.13 → 2:88:13 로 읽는다. 글꼴을 배운 적이 없어서다. 도트 날짜를 합성해 따로 학습했다. 미검출 12→10장          |


미사용 248장 최종: 92.3% (95% 신뢰구간 90.2~94.0%). 예선 구성과의 비교는 88.5% → 91.9%(+3.4%p, 개선 7장 / 악화 0장, p=0.0156)이고 인식기 칸이 +1.1%p 를 더했다. 악화 0장은 구조 때문이다 — 재시도 칸은 실패한 이미지에만 진입한다.

실측으로 기각한 선택지: 채택한 것보다 기각한 것이 많다 논리성 증거

| 시도                     | 측정 결과                    | 시도                       | 측정 결과                     |
|------------------------|--------------------------|--------------------------|---------------------------|
| 입력 해상도 상향 (960→3200px) | recall 불변, 비용 1.7배       | 위원회 기반 액티브 러닝            | 무작위 표집 대비 이득 없음           |
| 단일 전처리 13종 상시 적용       | +3.0%p, p=0.201          | EasyOCR 파이프라인 결합         | +0.0%p (상호보완 0장)          |
| 크롭 TTA (박스 변형 재인식)     | 68.4% → 62.5%            | EAN-13 바코드로 연도 순서 판별     | 발동 가능 이미지 0장              |
| 느슨한 꼬리 패턴 추가           | 64.5% → 63.8%            | det server 재시도 칸 (109MB) | 다른 집합 17장 → 평가셋 0장        |
| 흐릿한 사진 전용 전처리          | 오답이 오히려 또렷했다 (458 대 412) | 1600px 재시도 칸             | 580장 +0.6%p → 미사용 표본 0장   |
|                        |                          | 도트용 YOLO 파인튜닝            | 새로 2장 → 잡던 것 6장 놓침        |
|                        |                          | 다수결 (세 파이프라인 / 여덟 칸)     | 79.8%→69.2% · 93.6%→93.4% |

1. 어떤 숫자가 소비기한인가: 판별 규칙

설계 의도



이것이 과제의 본질이다. 상품 뒷면에는 제조일자·바코드·품목보고번호·전화번호·영양성분이 함께 인쇄돼 있어, 날짜 형태의 숫자를 찾는 것만으로는 부족하다. 그중 무엇이 소비기한인지를 가려야 한다.

OCR 은 2022와 02.14 를 다른 줄로 끊는데, 인접 조각을 이어 붙이면 복구된다. 비용 0에 48% → 68%로 단일 최대 개선이었다.

| 규칙               | 실측 근거                     |
|------------------|---------------------------|
| 4자리 연도 우선        | 정밀도 99.2% (2자리는 79.4%)    |
| 제조/소비 쌍이면 낮은 날짜  | 해당 사례 전부에서 성립             |
| 9자리+ 숫자 내부 매치 차단 | 품목보고번호 20130628332176 오탐  |
| 미래성 필터 금지        | 정답에 2020~2022년 과거 날짜 다수   |
| 부분 필드 출력         | 연·월·일이 독립 채점이므로 버리지 않고 회수 |

2. 제한된 CPU 환경에서의 속도·오탐 최적화

최적화 전략

| 전략                         | 근거가 된 실측                                          |
|----------------------------|---------------------------------------------------|
| 비용이 저렴한 경로로 90% 처리 2계층 구조  | 주력 0.37초 / 보조 2.19초. 보조가 필요한 이미지는 전체의 5%          |
| 인식 호출을 줄인다 박스 사전 필터(보조)    | rec 가 보조 경로 비용의 80.9%. det 박스 26,499개 중 날짜는 0.63% |
| 해상도를 낮춘다 960 → 640px (보조)  | 위로만 시험한 것이 실수였다. 내리자 정확도 +8.8%p, 비용 62%           |
| 실패한 것만 재시도 적응형 재시도         | 상시 전처리는 유의성 없음(p=0.201). 성공한 이미지를 오히려 손상시킨다       |
| torch 를 포함하지 않는다 전 경로 ONNX | 임포트만 해도 2.76 → 5.88초/장. paddle 과 OpenMP 스레드를 결합한다 |

| 측정 기준                              | 장당    | 500장 환산 | 제한 대비  |
|------------------------------------|-------|---------|--------|
| ① 추론 루프만 (모델 로딩 제외, 60장)           |       |         |        |
| torch 포함 환경 (참고)                   | 5.88초 | 2,939초  | 122% × |
| 보조 경로 단독                           | 2.19초 | 1,096초  | 46%    |
| 주력 경로 단독                           | 0.37초 | 184초    | 8%     |
| 1차 예선 제출 구성                        | 0.53초 | 267초    | 11%    |
| ② 본선 구성 · 단일 프로세스 순차 (채점과 같은 500장) |       |         |        |
| 계단 7칸 + 보조                         | 1.20초 | 614초    | 26%    |

계단이 늘어 예선 구성보다 2.3배 느려졌지만 제한의 26%로 여유가 있다. 80%가 1칸에서 끝나고(중앙값 0.39초) 계단을 오르는 20%가 시간을 쓴다. 꼬리가 무거워(상위 1% 11.1초) 표본이 작으면 평균이 낙관적으로 나온다 — 그래서 채점과 같은 500장으로 졌다.

가장 큰 속도 저하는 torch가 포함된 환경에서 발생했다.

set\_num\_threads(1) · KMP\_BLOCKTIME=0 · OMP\_WAIT\_POLICY=PASSIVE 를 모두 시도했지만 6초대에서 내려오지 않아 500장이 제한을 초과했다. 가중치를 ONNX로 내보내 torch를 제거하는 것이 해법이었고(변환 전후 박스 IoU 1.000 확인), 후보였던 EasyOCR 파이프라인도 같은 이유로 탈락했다. 그 결과 정확도를 높이면서 속도도 함께 개선됐다.

3. 데이터 직접 라벨링

가산점 증빙

배포 데이터 3,352장은 정답 라벨이 전혀 없다. 자체 도구(label/index.html)를 만들어 직접 판독·검수한 728장(배포분의 21.7%)으로 설계하고 검증했다. 이 라벨이 없었다면 세 파이프라인 중 어느 것이 나은지 판단할 방법 자체가 없었다. 실제로 최종 채택된 구성은 자체 평가("값이 채워진 행 수")만으로는 열세로 보이던 쪽이었다.

| 집합      | 장수  | 용도 · 상태              |
|---------|-----|----------------------|
| 튜닝셋     | 137 | 규칙 설계·파라미터 결정        |
| 1차 홀드아웃 | 48  | 연도 후행형 버그 발견         |
| 2차 홀드아웃 | 198 | 예선 판정 · 이후 오답 검토로 소진 |
| 3차 홀드아웃 | 197 | 중간 판정 · 오답 검토로 소진    |
| 4차 홀드아웃 | 148 | 본선 최종 판정 (미사용 표본)    |

라벨링 기준은 문서로 먼저 고정했다. 소비기한과 제조일자가 함께 인쇄되면 낮은 쪽, 일부 필드만 읽히면 그 필드만, 판독 불가·중의적인 7장은 제외. 무작위 30장을 사람이 다시 읽어 대조했을 때 30/30 일치했다(0건 오류의 95% 신뢰상한은 약 10%).

4. 추후 활용 계획 및 확장성

활용 전략

| 적용 도메인                              | 운영 구조                                                                                | 이 아키텍처가 맞는 이유                                                         |
|-------------------------------------|--------------------------------------------------------------------------------------|-----------------------------------------------------------------------|
| 편의점·마트 유통기한 관리 진열대 촬영 → 입박 상품 자동 집계 | 온디바이스(모바일 CPU). 주력 엔진만 사용하면 30MB·0.37초/장. 추론 단계에서 서버 왕복이 없어 네트워크 의존성과 통신 비용을 줄일 수 있음 | GPU를 전제하지 않아 그대로 단말에 올라간다. 성능이 낮은 단말은 보조 경로를 꺼서 축소 운영                 |
| 푸드뱅크 기부 식품 선별 기부 물품의 잔여 기한 일괄 판정    | 배치 서버. 단일 프로세스 시간당 약 6,800장, 코어 수만큼 병렬 확장                                            | 필드별 부분 출력(NONE-08-25)이 사람 검사 대상을 좁혀 준다                                |
| 물류창고 입고출고 자동화 입고 시 기한 판독 → 선입선출     | 옛지 게이트웨이 + 컨베이어 카메라                                                                  | 확장 경로는 엔진 교체다. OCR 엔진과 날짜 판별 규칙을 분리해, 엔진 교체 시 후처리 로직을 재사용할 수 있도록 설계했다 |